

# Introduction to Linear Algebra – 第六章

## (4): 正定矩阵与奇异值分解

*bourneli*

2016年12月

正定矩阵是一种特殊的对称的矩阵，很多应用中都会涉及正定矩阵的相关性质。正定矩阵比较有趣的一点是，它可以将线性代数中很多重要的概念串联起来，形成一个整体。SVD是正定矩阵的一个主要应用，它可以将任意矩阵分解成正交矩阵和对角矩阵的乘积，可以用于数据压缩。

### 正定矩阵性质

对称矩阵  $A$  具有下面5个性质中的一个，那么它就具备了剩下的其他性质，并且被称之为正定矩阵：

1. 所有主元大于0
2. 所有左上行列式大于0
3. 所有特征值大于0
4.  $x^T A x > 0, x \neq 0$
5.  $A = R^T R$  并且  $R$  的列线性独立

### 例子

已知矩阵  $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 。计算主元，得到  $\text{rref}(A) = \begin{bmatrix} 2 & 1 \\ 0 & \frac{3}{2} \end{bmatrix}$ 。可以轻松计算特征值，左上行列式。

二次形式展开  $\begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 2(x_1^2 + x_1 x_2 + x_2^2) = 2(x_1 + \frac{1}{2}x_2)^2 + \frac{3}{2}x_2^2 > 0$


$A = LDL^T$  分解, 然后变成  $R$

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ \frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & \frac{3}{2} \end{bmatrix} \begin{bmatrix} 1 & \frac{1}{2} \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ \frac{1}{2} & 1 \end{bmatrix} \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{\frac{3}{2}} \end{bmatrix} \begin{bmatrix} \sqrt{2} & 0 \\ 0 & \sqrt{\frac{3}{2}} \end{bmatrix} \begin{bmatrix} 1 & \frac{1}{2} \\ 0 & 1 \end{bmatrix}$$

2乘2矩阵，完全符合上面的性质。

### 正定矩阵性质证明

上面有5个性质，如果每两个互相证明，那么需要证明20个定理，非常繁琐。其实，可以用图的角度看待这个问题，将每个性质看作图的顶点，如果性质之间具有推导特性，看作一条有向边。只要任意一个点出发，都可以到达其他顶点，那么问题就解决了，并且需要证明的定理也不需要20个。经过观察，可以得到下面的推导图，



根据上面的推导图，现在只需要证明6个定理，即可达到目的，下面逐个证明。

## 证明：4 $\Rightarrow$ 3

命题 若对称矩阵A有性质  $x^T A x > 0, x \neq 0$ ，证明A的所有特征值均为正数。

证明

A对称，那么其必然可以对角化，有  $A = Q\Lambda Q^T$ ，且将正定性质代入，具有  $x^T Q\Lambda Q^T x > 0$ ，其中  $\Lambda$  是对角矩阵，对角元素为  $\lambda_1, \dots, \lambda_n$ 。令  $y = Q^T x = [y_1 \quad \dots \quad y_n]^T$ 。所以，最后有

$$y\Lambda y^T > 0 \Rightarrow \sum_{i=1}^n \lambda_i y_i^2 > 0$$

上述不等式需要对任意不等于0向量的x成立，由于  $Q^T$  是标准正交矩阵，也就是对任意不等于0向量的y成立，所以  $\lambda_i > 0$  必须横成立。

证毕

## 证明：3 $\Rightarrow$ 5

命题 若对称矩阵A所有特征值大于0，证明存在矩阵R，其列线性独立，且  $A = R^T R$ 。

证明

A对称，所以有  $A = Q\Lambda Q^T$ 。因为条件  $\lambda_i > 0$ ，所以有  $A = Q\Lambda^{\frac{1}{2}}(\Lambda^{\frac{1}{2}})^T Q^T$ ，令  $R = (Q\Lambda^{\frac{1}{2}})^T$ ，且  $R^{-1} = Q\Lambda^{-\frac{1}{2}}$ ，那么有R可逆且  $A = R^T R$ 。

证毕

## 证明：5 $\Rightarrow$ 4

命题 对称矩阵A有  $A = R^T R$  并且R的列线性独立，证明  $x^T A x > 0, x \neq 0$

证明

因为R列线性独立,  $x \neq 0$ , 所以  $Rx \neq 0$ 。

直接按照条件展开  $x^T Ax = x^T R^T Rx = (\|Rx\|)^2 > 0$  恒成立。

证毕

## 证明: $3 \Rightarrow 2$

命题 对称矩阵A的所有特征值大于0, 证明A的所有左上行列式大于0

证明

因为A所有特征值  $\lambda_i > 0$ , 所以有  $\|A\| = \prod_{i=1}^n \lambda_i > 0$ 。

假设  $A_k$  是矩阵A保留左上角k行和k列。因为对任意  $x \neq 0$ , 均有  $x^T Ax > 0$ , 所以对于特殊形式的  $x = (x_1, x_2, \dots, x_k, 0, \dots, 0) \neq 0, k = 1, 2, \dots, n$  仍然成立, 则  $A_k$  与A有如下关系

$$\begin{aligned} 0 &< (x_1, x_2, \dots, x_k, 0, \dots, 0) A (x_1, x_2, \dots, x_k, 0, \dots, 0)^T \\ &= (x_1, x_2, \dots, x_k) A_k (x_1, x_2, \dots, x_k) \end{aligned}$$

所以  $A_k$  所有特征值大于0 (利用  $4 \Rightarrow 3$ ), 所以  $\|A_k\| > 0$ 。

证毕

## 证明: $2 \Rightarrow 1$

命题 对称矩阵A所有左上行列式大于0, 证明A的所有主元大于0

证明

因为  $\|A_k\| > 0$ , 所以A可逆。那么, 可以只通过基础消元 (特征值不变), 而不需要基础换行或基础乘法 (这些导致特征值变化), 将A化简为只有主对角线的矩阵, 此时对角线上的元素就是主元  $p_i$ , 并且此过程做上角行列式保持不变。所以有  $\|A_k\| = \prod_{i=1}^k p_i, \|A_{k-1}\| = \prod_{i=1}^{k-1} p_i$ , 推导出  $p_k = \frac{\|A_k\|}{\|A_{k-1}\|} > 0$ 。

证毕

## 证明: $1 \Rightarrow 4$

命题 对称矩阵A所有主元大于0, 证明  $x^T Ax > 0, x \neq 0$

证明

使用LDU分解, 由于A对称, 所以  $A = LDL^T$ , 其中D是对角矩阵, 且每个元素  $p_i$  是A的主元。代入x, 有  $x^T LDL^T x$ 。令  $y = L^T x = (y_1, y_2, \dots, y_n)$ 。所以  $x^T LDL^T x = y^T D y = \sum_{i=1}^n p_i y_i^2 > 0$ 。

证毕

至此, 所以必要的定理已经证明完成, 得到了完成的证明图, 最终的问题得到了证实。

## 正定应用

- 假设C是正定, 且A列线性独立, 证明  $A^T C A$  正定, 工程应用中的重要定理。

证明:  $R = \Lambda^{\frac{1}{2}} Q A$ , 易证明R线性独立。因为只有  $x=0$  时,  $RX = 0$  才成立, 否则不行。

- 二元矩阵中, 正定的二次型是椭圆形。
- 很多概率模型需要其中的矩阵正定。

# 奇异值分解SVD

假设矩阵 $\mathbf{A}$ 为任意维度， $\mathbf{A}$ 的秩为 $r$ ，如果不为方正，那么自然是得不到特征值和特征向量的。但是 $\mathbf{A}^T \mathbf{A}$ 与 $\mathbf{A} \mathbf{A}^T$ 却是对称的，而且根据正定性，它们是半正定矩阵。所以，可以计算相关的特征值和特征向量。那么，这两个矩阵的特征向量是否有什么关系呢？

## 大胆假设

我们来做一些大胆的设想，假设下面条件统统成立：

1.  $v_1, \dots, v_r \in R(\mathbf{A}), u_1, \dots, u_r \in C(\mathbf{A})$
2.  $v_1, \dots, v_r$ 是正交单位矩阵,  $u_1, \dots, u_r$ 是正交单位矩阵
3.  $\mathbf{A}v_1 = \rho_1 u_1, \mathbf{A}v_2 = \rho_2 u_2, \dots, \mathbf{A}v_r = \rho_r u_r$
4.  $\rho_i > 0, i = 1, 2, \dots, r$

读者可能不禁要想，对于任意矩阵 $\mathbf{A}$ ，这种假设是不是太过苛刻！先不管那么多，假设成立，可以得到

$$\mathbf{A} \begin{bmatrix} v_1 & \dots & v_r \end{bmatrix} = \begin{bmatrix} u_1 & \dots & u_r \end{bmatrix} \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$$

由于 $v_i, u_i$ 均是正交的，所以可以使用Gram-Schmidt方法将其扩展到整个行空间和列空间，得到下面

$$\mathbf{A} \underbrace{\begin{bmatrix} v_1 & \dots & v_r & v_{r+1} & \dots & v_n \end{bmatrix}}_V = \underbrace{\begin{bmatrix} u_1 & \dots & u_r & u_{r+1} & \dots & u_m \end{bmatrix}}_U \underbrace{\begin{bmatrix} \sigma_1 & & & & \\ & \ddots & & & \\ & & \sigma_r & & \\ & & & 0 & \\ & & & & \ddots & \\ & & & & & 0 \end{bmatrix}}_{\Sigma}$$

简化上面的表达式

$$\mathbf{A}V = U\Sigma \Rightarrow \mathbf{A} = U\Sigma V^T$$

也就是说，如果矩阵 $\mathbf{A}$ 满足上面这些条件，就可以将 $\mathbf{A}$ 分解成两个正交矩阵和一个对角矩阵，是不是非常优美！由于 $\Sigma$ 后面对角线元素都为0，所以可以进一步简化：

$$\underbrace{\mathbf{A}}_{m \times n} = \underbrace{U_r}_{m \times r} \underbrace{\Sigma_r}_{r \times r} \underbrace{V_r^T}_{r \times n}$$

$U_r$ 是 $U$ 保留前 $r$ 列， $V_r^T$ 是 $V^T$ 保留前 $r$ 行， $\Sigma_r$ 是保留前 $r$ 行与 $r$ 列。

## 小心求证

首先从 $\mathbf{A}^T \mathbf{A}$ 开始，由于半正定性，所以可以将其特征值写成如下形式

$$\mathbf{A}^T \mathbf{A} v_i = \sigma_i^2 v_i \quad (1)$$

由 $\mathbf{A}^T \mathbf{A}$ 半正定性，可得 $v_i$ 标准正交，且令 $\sigma_i > 0 (i = 1, 2, \dots, r)$ 称之为奇异值(注意:不要与特征值混淆)。对公式(1)两边乘以 $v_i^T$ 得到

$$v_i^T \mathbf{A}^T \mathbf{A} v_i = v_i^T \sigma_i^2 v_i \Rightarrow \|\mathbf{A} v_i\|^2 = \sigma_i^2 \Rightarrow \sigma_i = \|\mathbf{A} v_i\| \quad (2)$$

从公式(2)可以了解到, 奇异值 $\sigma_i$ 是 $A^T A$ 单位特征向量 $v_i$ 在矩阵 $A$ 列空间的投影向量的模长(很绕口, 看看就好, 不用太在意)。然后, 继续对公式(1)两边乘以 $A$ , 构造出 $AA^T$

$$AA^T Av_i = A\sigma_i^2 v_i \Rightarrow AA^T(Av_i) = \sigma_i^2(Av_i) \quad (3)$$

线性代数中有很多重要证明利用了括号变化, 上面又是一个重要的例子。根据公式(3), 可以发现 $AA^T$ 与 $A^T A$ 具有相同的特征值 $\sigma_i^2$ 。并且特征向量具有关系, 令 $u_i$ 是 $AA^T$ 的特征向量, 明显有 $u_i$ 正交, 且由公式(3),  $u_i = Av_i$ 。但是正交特征矩阵一般需要为单位矩阵, 而且由公式(1)可以容易得到模长, 所以最终令 $u_i = \frac{Av_i}{\sigma_i}$ 。上面的假设得到了证明。

事实证明, 上面的假设并不苛刻, 对于任意 $A$ 都可以找到这些向量和奇异值将其分解, 不得不佩服发现SVD的数学家们。

## 计算策略

由于 $A^T A$ 与 $AA^T$ 的特征值相同, 计算策略显而易见, 计算维度较小的那个矩阵的特征值。因为特征值的复杂度是 $O(n^3)$ ,  $n$ 是矩阵的行数, 当行数很高时, 根本无法计算。spark中的SVD也是按这种策略实现。

## 奇异值的权重

奇异值都是大于0的实数, 可以认为是权重, 所以将奇异值按照从大到小的方式延对角线排列, 可以得到唯一的分解。将SVD分解按代数形式展开, 如下

$$A = [u_1 \quad \cdots \quad u_r] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \begin{bmatrix} v_1^T \\ \vdots \\ v_r^T \end{bmatrix} = \sum_{i=1}^r \sigma_i u_i v_i^T$$

$A$ 是 $r$ 个秩为1的矩阵的线性组合, 且每个矩阵是由单位向量乘法构成模, 奇异值是系数。如果最后的奇异值比较小, 可以忽略, 对 $A$ 的整体影响比较小, 这样可以做有损压缩。